


# Aprendizado de Máquina: Conceitos, Definições e Aplicações




Prof. Dr. Márcio Andrey Teixeira  
Instituto Federal de São Paulo – Campus Catanduva  
Catanduva, SP  
[marcio.andrey@ifsp.edu.br](mailto:marcio.andrey@ifsp.edu.br)

# Agenda:

1. Aprendizado de Máquina: Conceitos e definições
2. Aprendizado de Máquina: Aplicações
3. Aprendizado de Máquina: o Futuro
4. Métodos de Aprendizagem: Supervisionado, não Supervisionado
5. Processo de Aprendizado

# Aprendizado de Máquina: Conceitos e definições



# Como Funciona o Aprendizado de Máquina?



- ✓ O Aprendizado de Máquina utiliza **algoritmos** para fazer análise de dados que automatiza a construção de modelos analíticos.
- ✓ Os algoritmos reconhecem padrões e se tornam capazes de fazer previsões. Pode-se dizer que uma máquina “aprende” com os dados quando ela consegue **melhorar o seu desempenho com o aumento de informação recebida**.



# Como Funciona o Aprendizado de Máquina?

- ✓ O aprendizado de máquina é frequentemente combinado com métodos de aprendizado profundo para estudar e observar algoritmos de IA. Diz-se que um programa de computador aprende a partir da experiência  $E$  em relação a uma classe de tarefas  $T$  e a uma medida de desempenho  $P$ , se seu desempenho nas tarefas em  $T$ , conforme medido por  $P$ , melhora com a experiência  $E$ .


# Como Funciona o Aprendizado de Máquina?



# Diferenças Entre Algoritmos de Aprendizado de Máquina e Métodos Tradicionais Baseados em Regras


Método baseado em

regra




- Programação explícita é usada para resolver os problemas.
- Regras podem ser determinadas manualmente.

Machine learning




- Modelos são treinados com base em amostras
- As regras de tomada de decisão são complexas ou difíceis de descrever
- As máquinas aprendem regras automaticamente.

# Como Funciona o Aprendizado de Máquina?





# Funções de Aprendizado



- ✓ A função objetivo  $f$  é desconhecida, e o algoritmo de aprendizado não pode obter uma função perfeita  $f$ .
- ✓ A função hipótese  $g$  aproxima a função  $f$ , mas pode ser diferente da função  $f$ .


# Principais problemas resolvidos por Aprendizado de Máquina

- ✓ Os problemas resolvidos *por Aprendizado de Máquina* são divididos em três subáreas principais:
- ✓ **Regressão:** Utiliza dados de entrada (preditores) já observados para prever uma resposta. Neste caso, prevê resultados em uma saída contínua, onde tenta-se mapear variáveis de entrada para alguma função contínua. Exemplos, estimar o preço de um imóvel baseando-se nas características da casa.
- ✓ **Classificação:** De forma similar a regressão, a classificação utiliza dados de entrada (preditores), onde busca-se prever a categoria de uma observação dada. Prevê resultados em uma saída discreta. A partir de imagens de animais, classificar gatos e cachorros.

# Como Funciona o Aprendizado de Máquina?

- ✓ **Agrupamento:** Também conhecido como ***Clustering***, tem como objetivo agrupar dados em grupos “clusters” de acordo com as características dos dados. Isso é feito de acordo com as similaridades dos dados.

# Como Funciona o Aprendizado de Máquina?



**Algoritmos de *Machine Learning***

+



**Base de dados**

=



**Aprendizado de máquina**

# Métodos de Aprendizagem

Supervisionado

O algoritmo recebe um conjunto de dados (treinamento e teste) que definem aquilo que deverá ser buscado (classificado) pelo algoritmo


Não-Supervisionado

O algoritmo desenvolve suas próprias conclusões a partir de um conjunto de dados


Semi-Supervisionado

Uma mistura dos métodos supervisionados e não supervisionados

# Aprendizagem de Máquina Supervisionada




# Aprendizagem de Máquina Supervisionada



# Aprendizagem de Máquina Supervisionada

✓ **Aprendizagem supervisionada. Exemplo:**





# Aprendizagem de Máquina Supervisionada

## ✓ Aprendizagem supervisionada. Exemplo:


Dada o conteúdo do email, classificar em spam ou não spam



# Aprendizagem de Máquina Supervisionada

## Exemplos de Algoritmos de Regressão


- ❑ Regressão Linear (*Linear Regression*)
- ❑ Support Vector Machine (SVM)
- ❑ Árvore de decisão (*Decision Tree*)
- ❑ Random Forest Regression



# Aprendizagem de Máquina Supervisionada



## Exemplos de Algoritmos de Classificação

- ❑ Logistic Regression
- ❑ K-Nearest Neighbors (K-NN)
- ❑ Support Vector Machine (SVM)
- ❑ Naive Bayes
- ❑ Árvore de decisão (*Decision Tree Classification*)
- ❑ Random Forest Regression (Classification)



# Aprendizagem de Máquina não Supervisionada



## Aprendizagem não Supervisionada




# Aprendizagem de Máquina não Supervisionada

**Objetivo: Encontrar padrões em dados sem rótulos**

Aprendizagem não  
Supervisionada




Unlabelled Data



Machine




Results




# Aprendizagem de Máquina Não-Supervisionada

## ✓ Aprendizagem não supervisionada



# Aprendizagem de Máquina Não-Supervisionada


## ✓ Aprendizagem não supervisionada




Algoritmo

# Aprendizagem de Máquina Não-Supervisionada

## ✓ Aprendizagem não supervisionada




Algoritmo






# Aprendizagem de Máquina Não-Supervisionada

## ✓ Aprendizagem não supervisionada



Algoritmo




# Aprendizagem de Máquina não Supervisionada

## Exemplos de algoritmos não supervisionados

- ❑ K-Means Clustering
- ❑ Hierarquical Clustering
- ❑ Apriori Algorithm for Learning Association Rule
- ❑ Principal Component Analysis


# Aprendizagem de Máquina Semi-Supervisionada

**Objetivo:** Utiliza uma parte de dados rotulados para classificar uma grande quantidade de dados não rotulados.



Ref: <https://www.enjoyalgorithms.com/blogs/supervised-unsupervised-and-semisupervised-learning>

# Aprendizagem de Máquina não Supervisionada



# Aprendizagem de Máquina Semi-Supervisionada


## Exemplo de algoritmos semi-supervisionados

- ❑ Semi-Supervised Support Vector Machines (S3VM)
- ❑ Self-trained Naïve Bayes Classifier

# Aprendizagem de Máquina por Reforço

O agente procura cumprir uma determinada tarefa, inicialmente com uma abordagem de tentativa e erro.

Posteriormente, o resultado de cada tentativa são utilizados para treinar o agente por meio de um sistema de recompensa/punição. **Aprende com os erros.**




# Aprendizagem de Máquina por Reforço

## Elementos principais do Aprendizado por Reforço

1. **Agente** – Quem aprende e toma decisões (ex.: robô, IA de um jogo, algoritmo de controle).
2. **Ambiente** – Onde o agente atua (ex.: um jogo, um simulador, um mundo real).
3. **Estado (State)** – Situação atual do ambiente que o agente pode observar.
4. **Ação (Action)** – Escolha que o agente faz em um estado específico.
5. **Recompensa (Reward)** – Feedback numérico indicando se a ação foi boa ou ruim.
6. **Política (Policy)** – Estratégia usada pelo agente para decidir qual ação tomar.
7. **Função de Valor (Value Function)** – Estimativa de quão bom é estar em um estado, considerando recompensas futuras.

# Aprendizagem de Máquina por Reforço

- Um modelo de aprendizado por reforço aprende com o ambiente, toma ações e ajusta as ações com base em um sistema de recompensas.



**O aprendizado por reforço** sempre tenta encontrar a melhor ação.



# Aprendizagem de Máquina por Reforço

## Analogia simples

Imagine um cachorro aprendendo truques:

**Estado:** "o cachorro está sentado"

**Ação:** "ficar parado" ou "pegar a bolinha"

**Recompensa:** ganhar um petisco (+) ou não ganhar nada (-)


Com o tempo, ele aprende quais ações trazem mais recompensas.

# Aprendizagem de Máquina por Reforço

## Exemplos de algoritmos de aprendizagem por reforço

- Upper Confidence Bound (UCB)
- Thompson Sampling

# Processo de Aprendizado



# Processo de Aprendizado

## Conceito Básico de Aprendizado de Máquina - Conjunto de Dados

- **Dataset:** Conjunto de Dados: coleção de dados usada em tarefas de aprendizado de máquina, onde cada dado é chamado de amostra. Itens ou atributos que refletem a representação ou a natureza de uma amostra em um aspecto específico são chamados de características.
- **Training set:** conjunto de dados usado no processo de treinamento, onde cada amostra é chamada de amostra de treinamento.
- **Test set:** conjunto de dados usado no processo de teste, onde cada amostra é chamada de amostra de teste. Testar refere-se ao processo em que o modelo aprendido é usado para previsão

# Processo de Aprendizado


## □ Typical dataset composition

|              |   | Feature 1 | Feature 2 | Feature 3 | Label       |             |
|--------------|---|-----------|-----------|-----------|-------------|-------------|
|              |   | No.       | Area      | Location  | Orientation | House Price |
| Training set | 1 | 100       | 8         | South     | 1000        |             |
|              | 2 | 120       | 9         | Southwest | 1300        |             |
|              | 3 | 60        | 6         | North     | 700         |             |
|              | 4 | 80        | 9         | Southeast | 1100        |             |
| Test set     | 5 | 95        | 3         | South     | 850         |             |

# Processo de Aprendizado

## A importância do processamento dos dados


- Os dados são cruciais para os modelos e determinam o escopo das capacidades do modelo. Todos os bons modelos exigem bons dados.



# Processo de Aprendizado

## A limpeza dos Dados

□ O que os cientistas de dados passam o tempo fazendo para o aprendizado de máquina:



## Processo de Aprendizado

### A limpeza dos Dados

- ✓ A maioria dos modelos de aprendizado de máquina processa características, que geralmente são representações numéricas de variáveis de entrada que podem ser usadas no modelo.
- ✓ Na maioria dos casos, apenas dados pré-processados podem ser utilizados pelos algoritmos. O pré-processamento de dados envolve as seguintes operações:
  - Filtragem de dados
  - Tratamento de perda de dados
  - Tratamento de possíveis erros ou valores anômalos
  - Mesclagem de dados de múltiplas fontes
  - Consolidação de dados



## Processo de Aprendizado

### Dados “Sujos”

- Os dados brutos geralmente contêm problemas de qualidade de dados:
  - Incompleto: Dados incompletos ou falta de atributos ou valores relevantes..
  - Ruído: Os dados contêm registros incorretos ou pontos anômalos.
  - Inconsistência: Os dados contêm registros conflitantes.

| #  | Id     | Name   | Birthday   | Gender | IsTeacher? | #Students | Country     | City   |
|----|--------|--------|------------|--------|------------|-----------|-------------|--------|
| 1  | 111    | John   | 31/12/1990 | M      | 0          | 0         | Ireland     | Dublin |
| 2  | 222    | Mery   | 15/10/1978 | F      | 1          | 15        | Iceland     |        |
| 3  | 333    | Alice  | 19/04/2000 | F      | 0          | 0         | Spain       | Madrid |
| 4  | 444    | Mark   | 01/11/1997 | M      | 0          | 0         | France      | Paris  |
| 5  | 555    | Alex   | 15/03/2000 | A      | 1          | 23        | Germany     | Berlin |
| 6  | 555    | Peter  | 1983-12-01 | M      | 1          | 10        | Italy       | Rome   |
| 7  | 777    | Calvin | 05/05/1995 | M      | 0          | 0         | Italy       | Italy  |
| 8  | 888    | Roxane | 03/08/1948 | F      | 0          | 0         | Portugal    | Lisbon |
| 9  | 999    | Anne   | 05/09/1992 | F      | 0          | 5         | Switzerland | Geneva |
| 10 | 101010 | Paul   | 14/11/1992 | M      | 1          | 26        | Ytali       | Rome   |

Missing value

Invalid value

Misfielded value

Invalid duplicate  
items

Incorrect  
format

Dependent attributes

Misspelling

# Processo de Aprendizado

## Conversão dos dados


- Os dados pré-processados precisam ser convertidos em uma representação adequada para modelos de aprendizado de máquina. Os seguintes métodos são normalmente usados para converter dados:
  - Codificação de dados categóricos em valores numéricos para classificação
  - Conversão de dados numéricos em dados categóricos para reduzir os valores das variáveis (por exemplo, segmentação de dados de idade)
  - Outras Conversões:
    - Incorporar palavras em textos para convertê-las em vetores de palavras (tipicamente, modelos como word2vec e BERT são usados)
    - Processamento de dados de imagem, como conversão de espaço de cor, conversão de imagem em escala de cinza, transformação geométrica, características Haar-like e aprimoramento de imagem
    - Engenharia de Feature:
      - Normalização e padronização de características para garantir que diferentes variáveis de entrada de um modelo estejam no mesmo intervalo de valores.
      - Aumento de características: combinar ou converter as variáveis existentes para gerar novas características, como médias.



## Processo de Aprendizado

### Necessidade da Seleção de Features


- Geralmente, um conjunto de dados possui muitas características, algumas das quais podem **ser desnecessárias ou irrelevantes** para os valores a serem previstos.
- A seleção de características é necessária nos seguintes aspectos:



# Processo de Aprendizado

## Métodos de seleção de Feature

### □ Exemplo: Filtragem



Processo do método de filtragem

Ao avaliar a correlação entre cada característica e o atributo alvo, um método de filtragem pontua cada característica usando uma medida estatística e, em seguida, ordena as características pela pontuação. Isso pode preservar ou eliminar características específicas.

Métodos comuns:

- Pearson correlation coefficient
- Chi-square coefficient
- Mutual information

Limitação do método de filtragem:

- Os métodos de filtragem tendem a selecionar variáveis redundantes porque não consideram as relações entre as características.



**Prof. Dr. Marcio Andrey Teixeira**

**marcio.andrey@ifsp.edu.br**

**m.teixeira@ieee.org**

**<http://marcioteixeira.pro.br>**



**profmarcioteixeira.official**



**@matnetworking**

# Referências

[1] Teixeira, M.A.; Salman, T.; Zolanvari, M.; Jain, R.; Meskin, N.; Samaka, M. **SCADA System Testbed for Cybersecurity Research Using Machine Learning Approach**. Future Internet 2018, 10, 76.

Key-words: Cybersecurity, SCADA, Machine Learning Network Security.

[2] Deep Learning: do Conceito às Aplicações. <https://medium.com>

[3] Fundamentos dos Algoritmos de Machine Learning (com código Python e R).  
<https://www.vooo.pro/insights/fundamentos-dos-algoritmos-de-machine-learning-com-codigo-python-e-r/>

[4] <https://www.kdnuggets.com/>

[5] 10 Algoritmos de Machine Learning que você precisa conhecer.  
<http://www.semantix.com.br/blog/10-algoritmos-de-machine-learning/>

[6] <https://www.udemy.com/machinelearning>

# Referências

[7] 17 CASOS DE USO DE MACHINE LEARNING.

<http://datascienceacademy.com.br/blog/17-casos-de-uso-de-machine-learning/>