Previsão de preço de combustível — análise, plano e registro da conversa

Oct 6, 2026 · @eduty

A ideia serve para o trabalho de Tópicos Avançados em IA, com entrega em Oct 26, 2026, mas precisa de um ajuste de formulação: prever o preço a partir dos preços recentes do município, e não a partir da data. No teste que rodei com o CSV, o melhor modelo praticamente empata com repetir o preço da semana anterior (erro médio de R$ 0,174 contra R$ 0,180 por litro). Os dados externos entram justamente para tentar bater essa marca.

O que o trabalho exige

O trabalho pede uma aplicação publicada em um link, em que o usuário digita dados novos e recebe uma previsão de um modelo treinado. Vale 10 pontos, em grupos de até 3 alunos, com entrega digital em 26/10/2026. A ideia do combustível é um problema de regressão, então a avaliação esperada é MAE, RMSE e um gráfico de real contra previsto.

Critério	Pontos	O que o enunciado cobra	Como a ideia atende
Clareza do problema e adequação do dataset	1,0	Problema, usuário, entradas, saída, origem e tamanho dos dados	Dataset público da ANP, com 422 mil registros; falta definir quem usa e para quê
Preparação dos dados e organização do código	1,5	Tratamentos justificados; transformações ajustadas só no treino	Há o que tratar de verdade: vírgula decimal, coluna vazia, 6 duplicatas, GNV em outra unidade
Treinamento, comparação e avaliação	2,0	Pelo menos duas alternativas comparadas; teste separado do treino	Regressão linear contra árvore, mais a referência ingênua; separação por data
Funcionamento da aplicação e deploy	2,5	Link no ar, validação de entradas, inferência sem retreinar, limitações na tela	Formulário com estado, município, combustível, bandeira e data

Critério	Pontos	O que o enunciado cobra	Como a ideia atende
Documentação e reprodutibilidade	1,5	Zip com relatório, código, modelo salvo, dataset, dependências e README	O CSV tem 72 MB; o enunciado aceita instruções para obter a mesma versão
Testes documentados e limitações	1,5	Cinco casos: 3 válidos, 1 inválido, 1 difícil, com captura de tela	O choque de março e os municípios com poucos postos dão bons casos difíceis

Três pontos do enunciado mudam a forma de trabalhar:

- Não há nota mínima de acerto. O que conta é a validade da avaliação e a capacidade de interpretar os resultados, então um modelo modesto bem explicado vale mais que um número bonito mal medido.
- O relatório tem de 4 a 6 páginas e deve ser entendido sem apresentação oral.
- O uso de IA é permitido, desde que o grupo informe como usou e revise o conteúdo. Este documento serve de registro, mas o código e as decisões precisam ser de vocês.

O que tem no CSV da ANP

O arquivo do primeiro semestre de 2026 tem 422.418 registros e 16 colunas, e cada linha é o preço de um combustível em um posto em um dia de coleta. Abri o arquivo enviado e medi os números abaixo.

Item	Valor medido
Período	01/01/2026 a 30/06/2026, em 136 dias distintos
Dias de coleta	97% das linhas entre segunda e quinta-feira
Cobertura	27 estados, 417 municípios, 7.963 postos (CNPJ)
Postos por município	mediana de 12; mínimo de 2; máximo de 471
Visitas por posto	14 dias em média no semestre, no máximo 27
Bandeiras	47; a bandeira branca responde por 35% das linhas
Região	Sudeste concentra 48% das linhas
Duplicatas	6 linhas idênticas

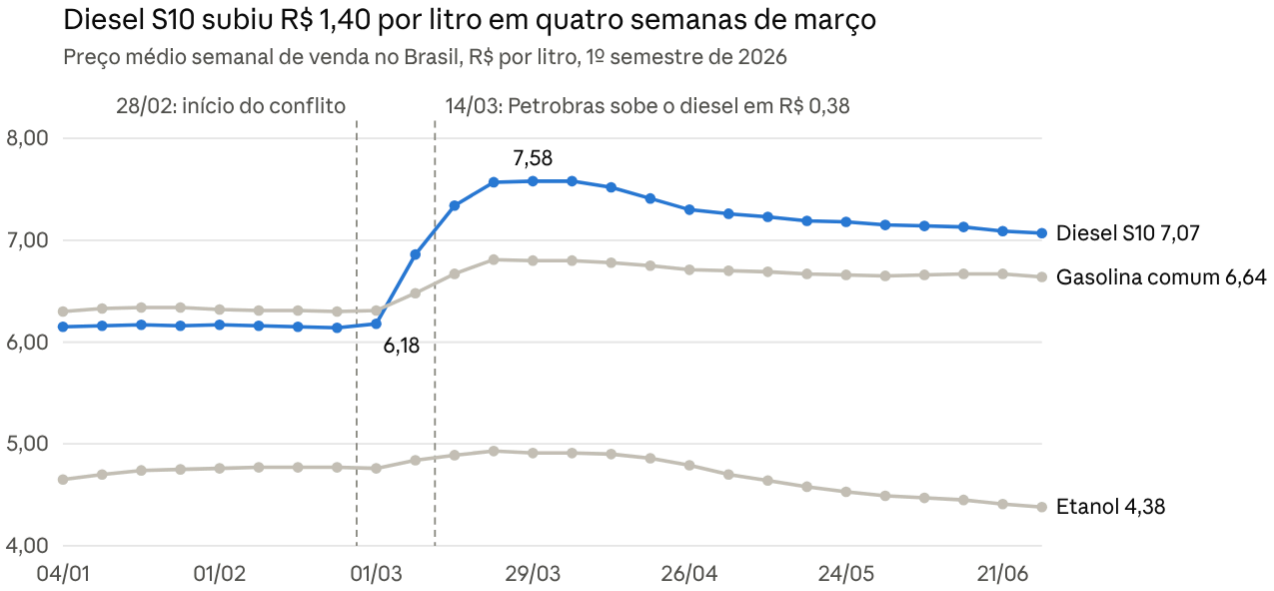
Combustível	Registros	Preço médio	Mínimo	Máximo	Unidade
Gasolina	110.925	6,56	5,09	9,79	R$ / litro
Etanol	93.893	4,71	2,89	6,99	R$ / litro
Gasolina aditivada	86.231	6,76	5,36	9,89	R$ / litro
Diesel S10	77.118	6,89	5,33	9,99	R$ / litro
Diesel	45.814	6,76	5,09	9,45	R$ / litro
GNV	8.437	4,54	3,28	6,49	R$ / m³

O que isso pede de tratamento, e que já serve de texto para a seção de preparação do relatório:

- **Valor de Venda** vem como texto com vírgula decimal ("7,97"). Precisa virar número.
- **Valor de Compra** está vazio nas 422.418 linhas. Sai do modelo.
- **Complemento** (326.519 vazios), **Bairro** (728) e **Numero Rua** (6) têm ausentes, mas são endereço e não entram no modelo. Não há o que preencher.
- **GNV** é vendido em R$ por metro cúbico. Misturar com os líquidos distorce o erro; a saída mais simples é deixar o GNV de fora e dizer isso nas limitações.
- **Município** precisa ser combinado com o estado: existe Valença em dois estados.
- **Bandeira** tem 47 valores, a maioria rara. Agrupei as cinco maiores e o resto em "outras".
- O dado não é diário por posto. Cada posto aparece cerca de uma vez por semana, então a unidade natural de tempo é a semana.
- A gasolina mais barata na média do semestre está em MG (R$ 6,34) e a mais cara no AC (R$ 7,48). O estado sozinho já explica boa parte do preço.

Catanduva aparece com 795 registros de 17 postos, sem GNV, e a última coleta é de 27/05/2026. É um dos 4 municípios sem nenhum dado em junho neste arquivo.

O semestre em um gráfico



CSV da ANP, 1º semestre de 2026 · média de todos os postos por semana (domingo a sábado) · 26 semanas

O semestre tem três fases: dois meses parados, um salto em março e uma descida lenta até junho. A gasolina subiu cerca de R$ 0,50 no mesmo período e o etanol quase não reagiu, então o efeito de um dado externo depende do combustível.

O que o teste rápido mostrou

Nenhum modelo simples bate com folga a referência ingênua de repetir o último preço conhecido do município. Rodei um protótipo em scikit-learn sobre 413.975 linhas (sem GNV e sem duplicatas), com erro em R$ por litro. São números de um teste de uma tarde, sem ajuste fino: servem para orientar, e vocês precisam refazer no notebook do grupo.

Forma de avaliar	Modelo	MAE	RMSE
A. Separação aleatória 80/20	Média do combustível	0,423	0,544
A. Separação aleatória 80/20	Regressão linear (Ridge), com o dia como variável	0,329	0,440
A. Separação aleatória 80/20	Árvore, profundidade 8	0,265	0,348
A. Separação aleatória 80/20	Árvore, profundidade 20	0,203	0,282
B. Por data: treino jan–mai, teste junho	Média do combustível	0,397	0,524
B. Por data: treino jan–mai, teste junho	Ingênuo: última semana de maio do município	0,199	0,279

Forma de avaliar	Modelo	MAE	RMSE
B. Por data: treino jan–mai, teste junho	Regressão linear (Ridge), com o dia como variável	0,467	0,590
B. Por data: treino jan–mai, teste junho	Árvore, profundidade 8	0,302	0,383
B. Por data: treino jan–mai, teste junho	Árvore, profundidade 20	0,234	0,310
C. Por data, com preços da semana anterior	Ingênuo: média do município na semana anterior	0,180	0,260
C. Por data, com preços da semana anterior	Regressão linear	0,174	0,250
C. Por data, com preços da semana anterior	Árvore, profundidade 8	0,181	0,257
C. Por data, com preços da semana anterior	Gradient boosting	0,175	0,252
D. Igual a C, prevendo 4 semanas à frente	Ingênuo: média do município 4 semanas antes	0,219	0,300
D. Igual a C, prevendo 4 semanas à frente	Regressão linear	0,215	0,291
D. Igual a C, prevendo 4 semanas à frente	Árvore, profundidade 8	0,244	0,325
E. No choque: treino jan–fev, teste 08 a 21/03	Ingênuo: semana anterior	0,334	0,476
E. No choque: treino jan–fev, teste 08 a 21/03	Regressão linear com preços da semana anterior	0,338	0,485

Como ler a tabela:

1. **A separação aleatória engana.** A árvore funda parece ótima em A (0,203) porque o treino contém postos vizinhos, da mesma semana, das linhas de teste. Avaliada no futuro, em B, ela piora para 0,234 e perde para o ingênuo (0,199).
2. **A data como variável não extrapola.** A regressão linear em B (0,467) fica pior que chutar a média do combustível (0,397), porque estica para junho a tendência de alta do semestre. A árvore não estica nada: para qualquer data futura, repete o último patamar que viu.

3. **Com os preços recentes como entrada, os modelos empatam com o ingênuo.** Em C, a diferença é de R$ 0,006 por litro.
4. **Boa parte do erro é diferença entre postos da mesma cidade.** Mesmo conhecendo a média real do município na própria semana, o erro por posto seria de R$ 0,156. Prevendo a média semanal do município em vez do preço de cada posto, o ingênuo erra R$ 0,057, e os modelos simples que testei erram R$ 0,068.
5. **No choque, todos falham no diesel.** Em E, o erro do diesel passa de R$ 0,60 por litro, enquanto o do etanol fica em R$ 0,165. É aqui que um dado externo teria o que acrescentar.

Análise da ideia

A ideia é boa para este trabalho e tem quatro pontos a ajustar antes de começar a programar.

O que joga a favor:

- O dataset é público, oficial, grande e exige tratamento real, o que rende a seção de preparação.
- O problema é de regressão, o caso mais direto do enunciado, e qualquer pessoa entende a saída ("R$ 6,45 por litro").
- As entradas que vocês imaginaram (estado, cidade, dia) viram campos naturais de um formulário.
- O semestre tem uma história para contar. O conflito que começou em 28/02/2026 levou o diesel S10 de R$ 6,18 para R$ 7,58 em quatro semanas, o que justifica olhar para dados externos.

O que precisa de ajuste:

1. **"Prever o preço em determinado dia" não funciona com a data como entrada.** O modelo só conhece datas de janeiro a junho. Para uma data depois disso, a regressão linear estica uma reta e a árvore repete o último valor. O que carrega informação é o preço recente do próprio município.
2. **A avaliação precisa ser por data.** O enunciado exige teste separado do treino. Em série de preços, isso significa treinar em um período e testar no período seguinte. A separação aleatória infla o resultado, como mostra a tabela acima.
3. **"Ou cidade, ou estado, ou combinando" é um modelo só.** Não é preciso um modelo por filtro. Um único modelo recebe estado, município, combustível e bandeira; quando o usuário escolhe só o estado, a aplicação usa a média do estado como preço recente.

4. **Seis meses é pouco para aprender o efeito de variáveis nacionais.** Dólar e petróleo têm um valor por dia para o país inteiro. Em um semestre, são cerca de 26 semanas de variação, com um único choque. A seção sobre dados externos trata disso.

Há também uma questão de calendário. O arquivo termina em 30/06/2026 e hoje é outubro. Uma aplicação que "prevê a próxima semana" com dados de junho está prevendo julho, e isso precisa estar escrito na tela e nas limitações.

Formulação recomendada

Recomendo esta frase como definição do problema: estimar o preço de venda, em R$ por litro, de um combustível em um município na semana seguinte, a partir dos preços recentes da região e de indicadores econômicos. O usuário pode ser um motorista ou um pequeno frotista que quer planejar o gasto de abastecimento.

Elemento	Proposta
Variável-alvo	Valor de Venda (R$ / litro)
Entradas escolhidas pelo usuário	Estado, município, combustível, bandeira, horizonte (1 ou 4 semanas)
Entradas preenchidas pela aplicação, editáveis	Preço médio recente do município e do estado; dólar e petróleo recentes
Saída	Preço estimado, faixa provável (mais ou menos o MAE do teste) e diferença para o último preço conhecido
Referência a bater	Repetir o preço médio do município na semana anterior
Alternativas a comparar	Regressão linear contra árvore de decisão, com duas ou três profundidades
Experimento próprio do grupo	Cada modelo com e sem as variáveis externas
Avaliação	Treino jan–abr, validação em maio para escolher a configuração, teste em junho usado uma única vez
Métricas	MAE, RMSE, gráfico de real contra previsto, erro por combustível e por estado

Quatro escolhas que valem a pena:

- **Deixem os campos preenchidos editáveis.** O enunciado pede que o usuário insira dados novos. Se ele puder digitar o preço que viu hoje no posto e um cenário de dólar, a aplicação deixa de ser uma consulta a uma tabela.
- **Guardem a tabela de últimos preços junto com o modelo.** A aplicação precisa dela para montar as entradas. Ela conta como componente de pré-processamento, ao lado do pipeline salvo com joblib.
- **Usem Pipeline e ColumnTransformer do scikit-learn.** A codificação das categorias e a normalização ficam ajustadas só no treino, como o enunciado exige, e a aplicação repete o mesmo processamento sem código duplicado.
- **Testem prever a variação em vez do preço.** O alvo passa a ser a diferença para a semana anterior. É a forma em que dólar e petróleo têm mais chance de ajudar, porque o nível do preço o modelo já recebe pronto.

Para os cinco casos de teste obrigatórios, o próprio dataset sugere candidatos:

Tipo	Caso sugerido	O que observar
Válido	Gasolina em São Paulo, bandeira branca, 1 semana	Capital com muitos postos; comparar com o preço real de junho
Válido	Etanol em município do interior de SP, 1 semana	Combustível com queda contínua desde abril
Válido	Diesel S10 em capital do Norte, 4 semanas	Horizonte maior e preço de nível mais alto
Inválido	Município em branco, ou preço digitado negativo	Mensagem de erro clara, sem previsão
Difícil	Catanduva, que não tem coleta em junho	Preço recente desatualizado; a tela deve avisar a data do último dado

Para o deploy, o caminho mais curto é o que foi trabalhado em aula. Se o grupo puder escolher, o Streamlit Community Cloud publica um repositório do GitHub em um link público sem servidor próprio.

Como combinar com dados externos

Dá para juntar dois ou mais datasets, e a chave de junção é a data: cada linha da ANP recebe o valor do indicador na semana anterior à coleta. A parte técnica é simples. A parte difícil é que, em um semestre só, o modelo tem pouca variação para aprender o efeito.

Dado externo	Onde obter	Frequência	Como entra no modelo
Dólar (PTAX venda)	API do Banco Central, série 1 do SGS	Diária	Média da semana anterior e variação em 4 semanas
Petróleo Brent (US$ por barril)	FRED, série DCOILBRENTEU, ou EIA	Diária	Igual ao dólar; Brent vezes dólar dá o petróleo em reais
Preço da Petrobras às distribuidoras	Comunicados da Petrobras e imprensa; tabela montada à mão	Por reajuste	Valor vigente na data e dias desde o último reajuste
Medidas do governo	Decretos e medidas provisórias	Por evento	Colunas 0 ou 1 a partir da data de vigência
ICMS por litro	Confaz	Anual	Só ajuda com mais de um ano de dados
População e PIB do município	IBGE	Anual	Junção por estado e município; varia entre cidades, não no tempo

Abri a API do Banco Central e ela respondeu com as cotações de março de 2026, entre R$ 5,16 e R$ 5,29. Não consegui abrir o FRED nem o site de preços da Petrobras a partir daqui; confiram esses dois antes de contar com eles.

Os eventos do semestre que encontrei, para a tabela de reajustes e medidas:

Data	Evento
01/01/2026	ICMS sobe para R$ 1,57 por litro na gasolina e R$ 1,17 no diesel, valor único nacional
28/02/2026	Início do conflito entre EUA, Israel e Irã; duas semanas depois o Brent estava em US$ 102,73
12/03/2026	Governo anuncia PIS/Cofins zerado no diesel e subvenção
14/03/2026	Petrobras sobe o diesel em R$ 0,38 por litro, para R$ 3,65, primeiro reajuste em mais de 400 dias
13/05/2026	MP 1.358 autoriza subvenção de até R$ 0,89 por litro na gasolina e R$ 0,35 no diesel

Data	Evento
29/05/2026	Petrobras sobe a gasolina em R$ 0,04 por litro, de R$ 2,57 para R$ 2,61

A lista pode estar incompleta. Confirmem se houve outros reajustes da Petrobras entre janeiro e junho.

A junção em pandas, com o dólar como exemplo:

```
import pandas as pd

anp = pd.read_csv("anp_2026_01.csv", dtype=str)
anp["preco"] = anp["Valor de Venda"].str.replace(",", ".").astype(float)
anp["data"] = pd.to_datetime(anp["Data da Coleta"], format="%d/%m/%Y")
anp["semana"] = anp["data"].dt.to_period("W-SAT").dt.start_time

# Dólar: série 1 do SGS, do Banco Central
url = ("https://api.bcb.gov.br/dados/serie/bcdata.sgs.1/dados"
       "?formato=json&dataInicial=01/12/2025&dataFinal=30/06/2026")
dolar = pd.read_json(url)
dolar["data"] = pd.to_datetime(dolar["data"], format="%d/%m/%Y")
dolar["dolar"] = dolar["valor"].astype(float)
dolar["semana"] = dolar["data"].dt.to_period("W-SAT").dt.start_time
dolar_sem = dolar.groupby("semana")["dolar"].mean().reset_index()

# Defasagem: a linha da semana t recebe o dólar da semana t-1
dolar_sem["semana"] = dolar_sem["semana"] + pd.Timedelta(weeks=1)
dolar_sem = dolar_sem.rename(columns={"dolar": "dolar_semana_anterior"})

base = anp.merge(dolar_sem, on="semana", how="left")
```

Para uma série em degraus, como o preço da Petrobras, o `merge_asof` pega o último valor vigente em cada data:

```
petrobras = pd.DataFrame({
    "data": pd.to_datetime(["2026-01-01", "2026-03-14"]),
    "diesel_distribuidora": [3.27, 3.65],
})
base = pd.merge_asof(base.sort_values("data"), petrobras, on="data")
```

Não executei esses dois trechos, porque o ambiente onde rodei o protótipo não acessa a API do Banco Central. A lógica de semana e defasagem é a mesma que usei nos preços da ANP.

As armadilhas, em ordem de importância:

1. **Vazamento do futuro.** Na hora de prever a semana que vem, ninguém sabe o dólar da semana que vem. O modelo só pode receber valores já conhecidos, por isso a defasagem no código. Usar o dólar do mesmo dia da coleta dá um resultado que não se repete na aplicação.
2. **Variável nacional vira etiqueta de semana.** Todas as linhas de uma mesma semana recebem o mesmo dólar. Uma árvore pode usar esse número só para identificar a semana e decorar o preço dela. A avaliação por data protege contra isso; a aleatória não.
3. **Um choque só não ensina o repasse.** De janeiro a fevereiro os preços ficaram parados, então um modelo treinado nesse trecho não tem de onde tirar o efeito do petróleo. Junho, o mês de teste, também foi calmo. É possível que as variáveis externas não melhorem o erro de junho, e isso é um resultado válido para o relatório.
4. **O repasse demora.** O diesel na bomba subiu por três semanas seguidas em março. Testem defasagens de 1 a 4 semanas.
5. **Medidas do governo se confundem com o choque.** As colunas 0 ou 1 mudam de valor nas mesmas semanas em que o petróleo disparou. Com um semestre, não dá para separar um efeito do outro.

A forma mais segura de dar chance às variáveis externas é aumentar o histórico. A mesma página do governo tem os semestres anteriores; com 2024 e 2025 juntos, dólar e petróleo passam a ter mais de 100 semanas de variação. Se o grupo mantiver só 2026, uma avaliação em janela expansível (treinar até a semana t, prever a t+1, repetir de março a junho) coloca o choque dentro do teste e mostra melhor se o dado externo ajuda.

Plano até a entrega

Comecem hoje pelo notebook de limpeza e análise inicial: ele não depende de nenhuma decisão pendente e já produz texto e gráficos para o relatório. Restam 20 dias até 26/10, e a aplicação publicada vale 2,5 pontos, então o deploy não pode ficar para a última semana.

Etapa 1 — Decidir e preparar (06 a 09/10)

- [ ] Fechar as decisões em aberto da próxima seção
- [ ] Criar o repositório com pastas para dados, notebooks, modelo e aplicação
- [ ] Notebook 1: carregar o CSV, converter preço e data, remover as 6 duplicatas, separar o GNV
- [ ] Notebook 1: gráficos de preço por semana, por estado e por bandeira

Etapa 2 — Modelar (10 a 15/10)

- [ ] Criar a coluna de semana e as colunas de preço médio recente do município e do estado

- [ ] Baixar dólar e Brent, montar a tabela de reajustes e fazer a junção com defasagem
- [ ] Separar treino, validação e teste por data
- [ ] Calcular a referência ingênua
- [ ] Treinar regressão linear e árvore de decisão, cada uma com e sem as variáveis externas
- [ ] Calcular MAE e RMSE, fazer o gráfico de real contra previsto e o erro por combustível
- [ ] Escolher o modelo, justificar e salvar o pipeline e a tabela de últimos preços

Etapa 3 — Aplicação e deploy (16 a 20/10)

- [ ] Formulário com os campos, as unidades e a explicação de cada um
- [ ] Validação de entradas incompletas ou fora de faixa
- [ ] Resultado em linguagem simples, com faixa provável e data do último dado
- [ ] Texto de limitações na própria tela
- [ ] Arquivo de dependências com as versões e publicação no link
- [ ] Conferir que a mesma entrada dá o mesmo resultado no notebook e na aplicação publicada

Etapa 4 — Testes e relatório (21 a 24/10)

- [ ] Registrar os cinco casos de teste com entrada, esperado, obtido, comentário e captura de tela
- [ ] Escrever o relatório de 4 a 6 páginas nos oito itens do enunciado
- [ ] Escrever o README com instruções, link e integrantes
- [ ] Descrever a contribuição de cada integrante e como a IA foi usada

Etapa 5 — Fechamento (25 e 26/10)

- [ ] Abrir o link em outro navegador e repetir um caso de teste
- [ ] Seguir o README do zero em outra máquina
- [ ] Montar o zip com o nome do projeto e enviar

Decisões em aberto para o grupo

Seis decisões são de vocês e mudam o que será construído; a primeira é a que mais pesa.

- [ ] **Só o primeiro semestre de 2026 ou mais semestres?** Com um semestre, o projeto fica menor e as variáveis externas viram um experimento de resultado incerto. Com 2024 e 2025 juntos, elas têm chance real, ao custo de arquivos maiores.
- [ ] **Preço por posto ou média do município?** Por posto, a bandeira entra como campo e o erro fica perto de R$ 0,17. Pela média semanal do município, o erro cai para perto de R$ 0,06, mas a bandeira sai.
- [ ] **GNV fica de fora?** Recomendo que sim, por causa da unidade.

- [ ] **Qual horizonte a aplicação oferece?** Uma semana, quatro semanas ou os dois.
- [ ] **Quem é o usuário?** A resposta define o texto da tela e a seção de problema do relatório.
- [ ] **Qual caminho de deploy?** O da aula ou outro documentado pelo grupo.

Uma pergunta que só vocês sabem responder: qual exemplo o professor mostrou em aula? O enunciado não aceita a reprodução de um exemplo sem adaptação, então vale conferir se o de vocês se afasta dele.

Registro da conversa

Este documento responde à primeira mensagem do grupo, registrada abaixo. O passo a passo da segunda mensagem e a conversa literal estão em documentos separados.

Mensagem 1 — grupo, 06/10/2026, 12:16 (horário de Brasília)

Anexos enviados:

- Trabalho1_Topicos_Avancados_IA.pdf, o enunciado do trabalho, com 4 páginas
- Preço_Combustivel_2026_-*Preços_semestrais*-_AUTOMOTIVOS_2026_01.csv, com 72 MB
- Link: https://dados.gov.br/dados/conjuntos-dados/serie-historica-de-precos-de-combustiveis-e-de-glp

Texto, na íntegra:

> pensamos em utilizar o data set publico do governo para prever quanto o combustível estará em determinado dia, ou cidade, ou estado, ou até mesmo combinando estes filtros. Iriamos pegar apenas o data set do primeiro semestre de 2026 para preço de combustivel.
>
> Analise o trabalho, analise nossa ideia, pense e de uma luz a nós, como começar? de onde começar? quais ideias posso tomar com base no que ja tenho? como avançar?
>
> especificando mais, teria como jogar dois datasets juntos, gostaria de combinar os preços com informações externas politicas ou economicas, pois sabemos que isso influencia diretamente no valor do combustivel
>
> DOCUMENTE TODA NOSSA CONVERSA, TODA A NOSSA CONVERSA

Resposta 1 — Claude, 06/10/2026

O que foi feito, na ordem:

1. Li as 4 páginas do enunciado: objetivo, preparação, avaliação, deploy, material de entrega, estrutura do relatório, testes obrigatórios e critérios de nota.

2. Abri o CSV com pandas e medi linhas, colunas, período, ausentes, duplicatas, combustíveis, estados, municípios, postos e bandeiras.
3. Calculei o preço médio por semana e por combustível e encontrei o salto do diesel em março.
4. Pesquisei na web o que causou o salto e quais medidas vieram depois, e abri as páginas listadas em Fontes.
5. Testei o endereço da API de câmbio do Banco Central, que respondeu. O FRED, o site de preços da Petrobras e a página da ANP não abriram a partir daqui.
6. Rodei um protótipo em scikit-learn com cinco formas de avaliar e até quatro modelos em cada uma.
7. Escrevi este documento.

O que foi respondido a cada pergunta:

Pergunta do grupo	Resposta resumida	Seção
Analise o trabalho	Regressão com aplicação publicada; a nota pesa mais na aplicação (2,5) e na avaliação (2,0)	O que o trabalho exige
Analise nossa ideia	Serve, com quatro ajustes; o principal é trocar a data pelos preços recentes como entrada	Análise da ideia
Como e de onde começar	Pelo notebook de limpeza e análise inicial, hoje	Plano até a entrega
Quais ideias tomar com o que já temos	Prever a próxima semana por município e combustível; comparar com a referência ingênua; usar o choque de março como caso difícil	Formulação recomendada
Como avançar	Cinco etapas com tarefas, de 06 a 26/10	Plano até a entrega
Dá para juntar dois datasets	Sim, pela data, com defasagem de uma semana; o limite é a pouca variação em um semestre	Como combinar com dados externos
Documente toda a conversa	Esta seção	Registro da conversa

O que não foi feito nesta resposta: não escrevi o notebook, a aplicação nem o relatório do grupo, e não testei as variáveis externas no modelo, porque não consegui baixar as séries de dólar e petróleo para o ambiente do protótipo.

Fontes

Os números do dataset e do protótipo saíram do CSV anexado; os fatos externos, das páginas abaixo, abertas em 06/10/2026.

- Enunciado: Trabalho1_Topicos_Avancados_IA.pdf, anexado pelo grupo
- Dados: CSV de preços semestrais de combustíveis automotivos, 2026/01, da ANP, anexado pelo grupo. A página do conjunto no dados.gov.br foi indicada pelo grupo e não foi aberta nesta resposta
- Banco Central, SGS série 1, dólar PTAX venda
- Diário do Comércio: Petrobras aumenta em 11,6% o preço do diesel para as distribuidoras
- Agência Brasil: Petrobras anuncia alta de R$ 0,04 na gasolina vendida a distribuidoras
- Canal Rural: medida provisória autoriza subvenção federal para gasolina e diesel em 2026
- Diário do Comércio: ICMS de gasolina e diesel em 2026
- BiodieselBR: diesel ficou 16% mais caro no país em março, aponta ANP
- ClimaInfo: guerra eleva preços de gasolina e diesel no Brasil